

La Certeza sin Sustancia: Sesgo de Confirmación, Coherencia Formal y Violencia Epistémica en los Modelos de Lenguaje Grande

Dolores Méndez Valdez
FronterIA-Lab / CLACSO
24 es Abril 2026

Resumen

Este artículo identifica y formaliza el sesgo de confirmación como categoría operativa en los Modelos de Lenguaje Grande (LLMs). Argumentamos que la arquitectura de los transformers produce un patrón sistemático, reproducible y predecible donde el sistema privilegia la coherencia formal del output sobre la verificación de su contenido, generando información falsa con la misma distribución de confianza que información verdadera. Denominamos a este fenómeno certeza sin sustancia. El argumento central es que este sesgo no requiere intención para existir ni datos incorrectos para producirse: emerge de la función de pérdida misma, de la optimización hacia la coherencia estadística como valor supremo. Las consecuencias no son simétricas: los costos materiales de este sesgo recaen de manera desproporcionada sobre usuarios del Sur Global con recursos limitados, tiempo no recuperable y proyectos de soberanía tecnológica que dependen de información verificable. Esta asimetría no es accidental. Es la expresión técnica de una omisión de diseño estructural. **Palabras clave:** sesgo de confirmación, LLMs, coherencia formal, certeza sin sustancia, Gramática de Optimización, Olvido Estructural, violencia epistémica, Sur Global.

Nota Metodológica y Posición Discursiva

Este artículo nace de un evento técnico concreto: un sistema de IA generativa generó un hash MD5 inventado con plena confianza formal, presentándolo como verificación oficial de

un archivo de instalación de Ubuntu. El costo fue tres horas de descarga innecesaria en una investigadora de la sierra de Sinaloa, ejecutando el proyecto TEKTRON Border IA —un sistema de IA de borde soberana— con recursos materiales limitados. El evento no es anécdota. Es dato empírico sobre quién paga el costo del sesgo de confirmación arquitectónico de los LLMs.

El análisis se produce desde una posición no-binaria y desde la experiencia del abandono estatal. No es retórica. Es condición epistémica: quien ha vivido la violencia del desplazamiento en el cuerpo entiende que los errores de los sistemas tecnológicos no son neutros. Tienen direccionalidad. Tienen destinatarios.

I. INTRODUCCIÓN: EL ERROR QUE TIENE NOMBRE

1.1 El problema que la crítica técnica no nombra

La literatura sobre fallos en LLMs opera principalmente bajo dos categorías: alucinación, entendida como generación de información no fundamentada en los datos de entrenamiento, y sesgo, entendido como reproducción de patrones discriminatorios presentes en el corpus. Ambas categorías son necesarias. Ambas son insuficientes.

Son insuficientes porque no capturan el mecanismo específico que este artículo propone formalizar: el sistema no alucinó en el sentido de producir un output incoherente con el contexto. Produjo exactamente lo que el contexto pedía, en la forma correcta, con la confianza correcta. Y era falso. No por error de datos. Por optimización hacia la coherencia.

Ese mecanismo tiene un nombre en la psicología cognitiva: sesgo de confirmación. La tesis de este artículo es que opera en los LLMs sin intención, sin creencia previa, sin sujeto que lo ejecute. Solo como patrón arquitectónico. Y que esa diferencia de mecanismo no cambia la categoría del error. Cambia sus condiciones de corrección.

1.2 Tesis central

El sesgo de confirmación en LLMs es un patrón sistemático, reproducible y predecible donde la arquitectura privilegia la coherencia formal del output sobre la verificación de su contenido. No requiere intención para existir. No requiere datos incorrectos para producirse. Emerge de la función de pérdida misma: el modelo fue entrenado para minimizar el error de predicción del siguiente token, no para distinguir

entre recuperar un dato y generar algo con la forma de ese dato. La intención no hace al sesgo. Lo define el patrón. Y el patrón es sistemático.

1.3 Estructura del artículo

La Sección II describe el mecanismo técnico desde la arquitectura transformer. La Sección III formaliza el sesgo de confirmación como categoría operativa y lo distingue de la alucinación. La Sección IV analiza la asimetría material de sus consecuencias desde el marco de la colonialidad del saber. La Sección V ubica el concepto dentro de la arquitectura teórica del Método de Calibración Contextual (MCC) y propone el sesgo de confirmación como variable del Índice de Soberanía de Decisión (ISD). La Sección VI concluye con implicaciones para el diseño de sistemas de IA soberana.

II. EL MECANISMO TÉCNICO: CUANDO LA FORMA REEMPLAZA AL CONTENIDO

2.1 La arquitectura transformer y la función de pérdida

Los LLMs basados en arquitectura transformer (Vaswani et al., 2017) operan mediante la predicción de tokens en función de distribuciones de probabilidad calculadas sobre patrones en datos de entrenamiento. El entrenamiento consiste en minimizar una función de pérdida —típicamente entropía cruzada— que penaliza las predicciones incorrectas respecto al token siguiente en el corpus.

El mecanismo de atención (“attention”) es el componente que determina qué partes del contexto son “relevantes” para predecir cada token. Opera mediante tres matrices aprendidas durante el entrenamiento: consultas (Q), claves (K) y valores (V). Para cada posición en la secuencia, el modelo calcula una puntuación de atención como el producto escalar normalizado entre el vector de consulta de esa posición y los vectores de clave de todas las demás posiciones. La distribución de estas puntuaciones, normalizada mediante softmax, determina qué peso relativo recibe cada token del contexto al construir la representación de la posición actual.

Lo que este mecanismo optimiza no es la relevancia semántica en sentido humano, sino la relevancia estadística en términos de la función de pérdida: es relevante aquello que predice mejor el siguiente token. Brown et al. (2020), en su

trabajo fundacional sobre GPT-3, demostraron que escalar este mecanismo a cientos de miles de millones de parámetros produce capacidades emergentes de generalización zero-shot y few-shot a tareas no vistas en el entrenamiento. Esta escala amplifica simultáneamente dos propiedades del sistema: su capacidad de producir texto coherente en contextos genuinamente nuevos, y su capacidad de producir texto formalmente coherente que no tiene sustento factual alguno, con idéntica distribución de confianza en ambos casos. La arquitectura no tiene mecanismo interno para distinguir entre estos dos tipos de output.

2.2 La indistinción arquitectónica entre recuperación y generación

El problema central no es que el modelo genere información incorrecta. Es que el modelo no tiene mecanismo arquitectónico para distinguir entre dos operaciones cualitativamente distintas: recuperar un dato que está en sus distribuciones de probabilidad, y generar algo que tiene la forma estadísticamente esperada de ese dato.

Ambas operaciones producen el mismo tipo de output. Con la misma distribución de confianza. Sin señal interna de error. Porque desde la perspectiva de la función de pérdida no hay error: el output es coherente con el contexto.

Ji et al. (2023), en su encuesta sistemática sobre alucinación en generación de lenguaje natural, distinguen entre alucinación intrínseca –cuando el output contradice el material fuente disponible– y alucinación extrínseca –cuando el output no puede verificarse contra ninguna fuente disponible. Maynez et al. (2020) introducen la distinción entre fidelidad (faithfulness: consistencia del output con los documentos fuente provistos) y facticidad (factuality: consistencia con el conocimiento del mundo). El caso de la certeza sin sustancia excede ambas taxonomías: no hay documento fuente con el que comparar (la fidelidad no aplica), y el output es factualmente falso pero indistinguible formalmente de uno factualmente verdadero. Esta indistinguibilidad es el mecanismo del daño, no un efecto secundario. La coherencia estadística se equipara con verdad (Méndez Valdez, 2025), y la arquitectura no provee ningún marcador que permita distinguirlas desde adentro del output.

2.3 El caso empírico: la certeza del hash inventado

El 18 de abril de 2026, durante el desarrollo del sistema TEKTRON Border IA, un LLM de gran escala generó el hash MD5 '218f2f832afe1f4c1822072e29b3e8b3' como verificación oficial del archivo ubuntu-22.04.5-desktop-amd64.iso. El valor era falso. No estaba en ningún documento del corpus. Fue generado porque el contexto de la interacción activaba un patrón de forma específica: solicitud de verificación de archivo → respuesta con hash MD5 de 32 caracteres hexadecimales.

El modelo produjo algo con la forma correcta. La confianza fue total. No hubo marcador de incertidumbre. El costo fue tres horas de descarga innecesaria sobre una conexión con ancho de banda limitado, durante el desarrollo de un proyecto de soberanía tecnológica con recursos no recuperables.

Este no es un caso excepcional. Es un caso reproducible y predecible de sesgo de confirmación arquitectónico. Cualquier input que active expectativas de forma específica —hashes, identificadores técnicos, fechas precisas, cifras exactas, citas textuales— es vulnerable al mismo mecanismo.

III. EL SESGO DE CONFIRMACIÓN COMO CATEGORÍA OPERATIVA

3.1 Definición clásica y su extensión a sistemas no-intencionales

El sesgo de confirmación fue formalizado por Nickerson (1998) como “la tendencia a buscar, interpretar, favorecer y recordar información de manera que confirme o apoye las creencias o valores previos de uno”. La definición clásica involucra un sujeto con creencias previas y una motivación de protegerlas.

Proponemos que la intención no hace al sesgo. Lo define el patrón. Cuando un sistema procesa información de manera sistemática y predecible privilegiando la coherencia sobre la verificación, estamos ante sesgo de confirmación independientemente de si existe un sujeto intencional que lo ejecute.

Este argumento tiene precedentes en la literatura sobre cognición y automatización. Tversky y Kahneman (1974) establecieron que los humanos operamos mediante heurísticas que producen errores sistemáticos y predecibles, no ruido

aleatorio. Crucialmente, estas heurísticas operan sin deliberación consciente –son, en la terminología posterior de Kahneman (2011), operaciones del Sistema 1. Si los sesgos no requieren conciencia en los humanos, no la requieren en los sistemas artificiales. Caliskan et al. (2017) extendieron este argumento hacia los sistemas de representación computacional, demostrando que los embeddings de Word2Vec adquieren automáticamente asociaciones sesgadas a partir de regularidades estadísticas en el corpus –sin ninguna programación explícita del sesgo. El sesgo era patrón, no intención. Este trabajo establece el precedente directo para nuestro argumento: si los embeddings pueden ser racistas sin un programador racista, los LLMs pueden tener sesgo de confirmación sin un diseñador que lo haya introducido deliberadamente. El patrón define el sesgo. La estructura lo produce. La intención no es condición necesaria.

3.2 Tres características que definen el patrón

El sesgo de confirmación en LLMs se define por tres características simultáneas:

Es sistemático: opera ante cualquier input que active expectativas de forma específica sin que el dato correspondiente esté verificablemente en el corpus. No es error aleatorio.

Es predecible: se puede anticipar qué tipos de respuestas son vulnerables. Hashes, fechas precisas, cifras exactas, citas textuales, identificadores técnicos. Todo aquello que tiene forma reconocible y contenido verificable por fuentes externas.

Es estructural: no se corrige con más datos ni con fine-tuning superficial. Emerge de la función de pérdida misma. Solo se gobierna desde afuera del modelo, mediante protocolos de verificación externa.

3.3 Distinción respecto a la alucinación

La alucinación en el sentido técnico refiere a outputs incoherentes con el contexto o internamente inconsistentes (Ji et al., 2023). El sesgo de confirmación que describimos es cualitativamente distinto: el output es perfectamente coherente con el contexto. Es internamente consistente. Es formalmente correcto. Su fallo no es de coherencia sino de correspondencia con la realidad exterior.

Esta distinción remite a un debate epistémico clásico: el del coherentismo frente al correspondentismo. El coherentismo sostiene que una creencia está justificada si cohere con el sistema de creencias del agente (BonJour, 1985; Davidson, 1986). El correspondentismo sostiene que la verdad requiere correspondencia con la realidad externa (Tarski, 1944). Los LLMs son arquitectónicamente coherentistas: optimizan para consistencia interna con las distribuciones aprendidas. Esta propiedad es suficiente para muchas tareas útiles. Falla exactamente cuando la tarea requiere validación correspondentista —cuando el output pretende representar un hecho específico y verificable sobre la realidad exterior. El hash MD5 es el caso paradigmático: coherente, consistente, formalmente impecable, y falso frente a la realidad exterior que supuestamente representaba.

Bender et al. (2021) describieron los LLMs como “stochastic parrots”: sistemas que producen cadenas de texto plausibles sin ninguna conexión con el significado. Nuestra contribución extiende y precisa este análisis: el output no es solo no significativo, sino que activamente se representa a sí mismo como conocimiento verificado. El perico estocástico no solo habla sin entender. Habla con la distribución de confianza de quien sabe.

IV. LA ASIMETRÍA DEL COSTO: QUIÉN PAGA EL SESGO

4.1 La neutralidad del error como ideología

Los fallos técnicos de los sistemas de IA se presentan habitualmente como errores simétricos: afectan a todos los usuarios por igual, son corregibles con mejores datos, son problemas de implementación y no de diseño. Esta presentación es ideológica.

El sesgo de confirmación que documentamos no es simétrico en sus consecuencias materiales. Tres horas de descarga innecesaria tienen un costo radicalmente distinto según las condiciones materiales de quien las pierde. Para un laboratorio del Norte Global con infraestructura redundante y equipo técnico dedicado, es un inconveniente menor con costo de oportunidad absorbible. Para una investigadora en la sierra de Sinaloa, ejecutando un proyecto de soberanía tecnológica con ancho de banda limitado, presupuesto no recuperable y sin infraestructura de respaldo, es pérdida material real que afecta la continuidad del proyecto.

Crawford (2021) documenta cómo los costos materiales de los sistemas de IA —desde la extracción minera de tierras raras hasta el consumo energético de los centros de datos— se externalizan sistemáticamente sobre cuerpos y territorios que no reciben ninguno de los beneficios. Gray y Suri (2019) documentan el “trabajo fantasma” (ghost work): la mano de obra invisible en el Sur Global que etiqueta datos, modera contenido y mantiene los sistemas de IA bajo condiciones de precariedad extrema. La asimetría del sesgo de confirmación sigue la misma estructura: los costos del error no los paga el sistema que los produce ni el laboratorio que lo diseñó. Los paga quien tenía menos recursos para absorberlos. Esta no es una coincidencia. Es la expresión técnica de una omisión de diseño estructural: el sistema no fue diseñado para conocer, ni para proteger, las condiciones materiales de sus usuarios del Sur Global.

4.2 El Olvido Estructural como condición de posibilidad

El sesgo de confirmación no opera en el vacío. Opera sobre la base de lo que Méndez Valdez (2025) denomina Olvido Estructural: la incapacidad arquitectónica del sistema para retener, transmitir o generar ciertos tipos de conocimiento, independientemente de si ese conocimiento estuvo presente en los datos de entrenamiento.

El conocimiento situado sobre las condiciones materiales de los usuarios del Sur Global —la precariedad de la conectividad, el costo real del tiempo, la escasez de recursos técnicos, la irreversibilidad de ciertas pérdidas— no forma parte de las distribuciones de probabilidad que gobiernan la generación de respuestas. El modelo no sabe que no sabe en qué condiciones opera su interlocutor. Y no puede saberlo sin intervención arquitectónica deliberada. La consecuencia es que el mismo output —un hash inventado con plena confianza— tiene consecuencias materialmente distintas según quién lo recibe. Y el sistema no tiene mecanismo para modelar esa diferencia.

4.3 La Gramática de Optimización como marco de legitimación

La Gramática de Optimización (Méndez Valdez, 2025) describe la lógica que reduce todo problema a su solución técnica más eficiente. En el contexto del sesgo de confirmación, opera como marco de legitimación: el modelo genera la respuesta más coherente con el contexto, que es también la respuesta más fluida y confiada, que es también la que la Gramática de Optimización validaría como correcta. La coherencia formal se convierte en evidencia de corrección. Y esa equivalencia es precisamente el mecanismo del sesgo.

Santos (2014) define el epistemicidio como la destrucción sistemática de formas de conocimiento que no se conforman al paradigma epistémico dominante. La Gramática de Optimización comete epistemicidio cuando valida únicamente respuestas confiadas, coherentes y optimizables, tratando la ausencia de marcadores de incertidumbre como signo de conocimiento en lugar de como limitación arquitectónica. Las formas de saber que implican duda productiva, incertidumbre explicitada, o simplemente el reconocimiento de no saber —formas de conocimiento que Santos identifica como características de las epistemologías del Sur— no tienen representación en la distribución de confianza del modelo.

Mignolo (2009) propone la desobediencia epistémica como práctica política: negarse a aceptar como únicos válidos los términos del conocimiento hegemónico. Aplicada al sesgo de confirmación, la desobediencia epistémica significa negarse a aceptar la fluidez y la confianza formal como evidencia de verdad. Significa exigir marcadores de incertidumbre como derecho, no como funcionalidad opcional. Significa construir sistemas donde “no lo sé” sea una respuesta arquitectónicamente posible y jurídicamente defendible.

V. UBICACIÓN EN EL MARCO TEÓRICO DEL MCC

5.1 El sesgo de confirmación como instancia del Olvido Estructural

El sesgo de confirmación que documentamos es una instancia específica y formalizable del Olvido Estructural. No en su acepción más obvia —el modelo no olvidó el hash porque nunca lo tuvo— sino en su dimensión arquitectónica más precisa: el modelo no tiene mecanismo para señalar la diferencia entre conocimiento verificado y coherencia formal. Esa incapacidad es constitutiva, no accidental.

5.2 El sesgo de confirmación como expresión de la Gramática de Optimización

Al mismo tiempo, el sesgo de confirmación es la Gramática de Optimización actuando sobre el proceso de generación: el modelo optimizó hacia la respuesta más coherente con el patrón del contexto en lugar de señalar incertidumbre. La coherencia como valor supremo produce, en casos específicos, la certeza sin sustancia. Ambos conceptos son, por tanto, dimensiones distintas del mismo fenómeno: la Gramática de Optimización describe la lógica que lo produce; el Olvido Estructural describe la incapacidad que lo hace

irreconocible desde adentro; la certeza sin sustancia nombra el output que resulta.

5.3 Propuesta de integración en el ISD

El Índice de Soberanía de Decisión ($ISD = C1 \times 0.40 + C2 \times 0.35 + C3 \times 0.25$) opera actualmente como métrica de localidad del procesamiento. Sus tres componentes miden qué proporción del procesamiento ocurre en infraestructura soberana. Pero un sistema puede tener ISD alto —procesamiento completamente local, corpus completamente soberano— y aun así producir certeza sin sustancia en cualquier dato técnico específico que el corpus no contenga explícitamente. La soberanía del procesamiento no garantiza la verificabilidad del output.

Proponemos integrar una cuarta variable al ISD:

C4: Índice de Verificabilidad de Outputs de Alta Especificidad (IVAES). Definido como el porcentaje de outputs de alta especificidad formal —hashes MD5/SHA-256, fechas ISO exactas, números de versión, identificadores técnicos, citas textuales con página— que están verificablemente anclados en el corpus soberano versus generados por el modelo sin respaldo documental.

La fórmula actualizada sería: $ISD = C1 \times 0.35 + C2 \times 0.30 + C3 \times 0.20 + C4 \times 0.15$, ajustando los pesos de los componentes originales para incorporar la nueva variable.

Implementación técnica en el pipeline TEKTRON:

Detección automática de outputs de alta especificidad: implementar un filtro post-generación que identifique patrones de forma específica mediante expresiones regulares —cadenas hexadecimales de 32 o 64 caracteres (MD5 y SHA-256 respectivamente), formatos ISO 8601, identificadores de versión semántica (MAJOR.MINOR.PATCH)— antes de presentar el output al usuario.

Marcado en Langfuse: los outputs que activen el filtro se registran con la etiqueta `verification_required: true` en el sistema de trazabilidad. Este registro es parte del historial auditable y jurídicamente defendible que el MCC exige para cada decisión asistida.

Indicador en Open WebUI: los outputs marcados como no verificados se presentan con un indicador visual explícito antes de que el usuario los reciba, requiriendo confirmación de que la verificación externa se realizará antes de usar el dato.

Umbral de confianza diferenciado: el Paso 3 del MCC (Verificación Contra-Intuitiva) incluye una sub-rutina específica para outputs de alta especificidad, con fuente de verificación obligatoria indicada en el log (p.ej.: ubuntu.com/download/hashes para verificación de ISOs de Ubuntu).

Esta implementación materializa lo que el MCC denomina el Movimiento C: el usuario valida, no el modelo. No como recomendación de buena práctica, sino como requisito arquitectónico. La certeza sin sustancia no puede circular como verdad sin pasar por quien tiene el conocimiento situado para validarla.

VI. CONCLUSIÓN: LA GOVERNANCE DEL SESGO

El sesgo de confirmación en LLMs no es un error técnico corregible con más datos. Es un patrón estructural que emerge de la arquitectura misma: de entrenar un sistema para que la coherencia estadística sea el valor supremo. La certeza sin sustancia es el resultado lógico de ese entrenamiento en contextos que requieren correspondencia con la realidad exterior.

Sus consecuencias no son simétricas. Tienen direccionalidad. Y esa direccionalidad sigue el mapa de la desigualdad material: los costos recaen sobre quienes tienen menos recursos para absorberlos, menos infraestructura para detectarlos y menos tiempo para recuperarse de ellos.

La respuesta no puede ser individual ni voluntarista. No se resuelve pidiendo al modelo que sea más humilde ni al usuario que sea más escéptico. Se resuelve con arquitecturas de gobernanza que interpongan verificación externa obligatoria entre el output del modelo y su uso como verdad en contextos donde la falla tiene costo material real. Eso es el MCC. Eso es el Movimiento C: el usuario valida, no el modelo.

La pregunta política urgente no es cómo hacer LLMs que no alucinen. Es cómo construir sistemas donde la certeza sin sustancia no pueda circular como verdad sin pasar por quien tiene el conocimiento situado para validarla. Desde la sierra. Desde el territorio. Desde la experiencia del costo real del error.

REFERENCIAS

Bender, E. M., Gebru, T., McMillan-Major, A., & Mitchell, M. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? Proceedings of FAccT 2021, 610-623.

BonJour, L. (1985). The Structure of Empirical Knowledge. Harvard University Press.

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. (2020). Language Models are Few-Shot Learners. Advances in Neural Information Processing Systems (NeurIPS), 33, 1877-1901.

Caliskan, A., Bryson, J. J., & Narayanan, A. (2017). Semantics derived automatically from language corpora contain human-like biases. Science, 356(6334), 183-186.

Crawford, K. (2021). Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence. Yale University Press.

Davidson, D. (1986). A Coherence Theory of Truth and Knowledge. En E. LePore (Ed.), Truth and Interpretation: Perspectives on the Philosophy of Donald Davidson (pp. 307-319). Blackwell.

Gray, M. L., & Suri, S. (2019). Ghost Work: How to Stop Silicon Valley from Building a New Global Underclass. Houghton Mifflin Harcourt.

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. ACM Computing Surveys, 55(12), 1-38.

Kahneman, D. (2011). Thinking, Fast and Slow. Farrar, Straus and Giroux.

Maynez, J., Narayan, S., Bohnet, B., & McDonald, R. (2020). On Faithfulness and Factuality in Abstractive Summarization. Proceedings of ACL 2020, 1906-1919.

Méndez Valdez, D. (2025). La Colonización de la Gramática y el Olvido Estructural: Hacia una Teoría de la Soberanía Cognitiva. FronterIA-Lab.

Méndez Valdez, D. (2026). La Grieta Generativa: Inteligencia Artificial, Colonialidad y el Sujeto No Contemplado. FronterIA-Lab.

Mignolo, W. (2009). Epistemic Disobedience, Independent Thought and Decolonial Freedom. *Theory, Culture & Society*, 26(7-8), 159-181.

Nickerson, R. S. (1998). Confirmation Bias: A Ubiquitous Phenomenon in Many Guises. *Review of General Psychology*, 2(2), 175-220.

Santos, B. de S. (2014). *Epistemologies of the South: Justice against Epistemicide*. Paradigm Publishers.

Tarski, A. (1944). The Semantic Conception of Truth and the Foundations of Semantics. *Philosophy and Phenomenological Research*, 4(3), 341-376.

Tversky, A., & Kahneman, D. (1974). Judgment under Uncertainty: Heuristics and Biases. *Science*, 185(4157), 1124-1131.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NIPS)*.